

基于数据驱动与深度学习

在原位自校准温度压力传感器中对温度
压力方程超高精度拟合的研究工作总结

汇报人：韩普宇

单位：南方科技大学 \ 南方海洋实验室

邮箱：12432627@mail.sustech.edu.cn

研究背景

实现精准原位自校准的技术壁垒：建立超高精度的传感器输出方程

◆ 现有传感器的局限性

尽管已有温盐深仪（CTD）、深海压力计等成熟设备，在深海观测中，传统传感器因高压低温环境下长期漂移而难以维持精度。

◆ 原位自校准技术的提出

其核心思想是在传感器内部建立参考基准，并结合在线算法，实现无需拆卸，实时修正，长期稳定。

◆ 高精度方程拟合的关键作用



在深海环境中，利用高精度方程拟合实现原位自校准，是突破温度压力传感器长期漂移和极端环境误差的关键路径。



核心要求-精度以及一定的通用性

寻找合适的温度压力剖面数据，拟合曲线，数据处理至可用于方程拟合。（一个区域）
用神经网络算法模拟出一个公式，此公式各点和曲线之间的误差小于**0.05K**。这个公式要用尽可能少的系数获得，但要保证**0.05K**的精度系数越少越好，但要保证精度**0.05K**用神经网络模拟数据组获得一个高准确度的公式，用它作为参考标准。然后用**最少项数**的函数去拟合参考标准的曲线。

- 1.寻找规律：你用单次的剖面（温度-压力）数据拟合出一个公式，满足最大误差0.05K。
- 2.方程：区域方程、区域四季方程、深度分层方程、深度压力规律验证等
- 2.验证：然后用这个公式的形式（带有未知系数）和其他剖面数据去计算系数，看误差。





传统回归类方法

多项式拟合、分段函数、非线性最小二乘回归，优点是简单直观，但在深海复杂非线性环境下往往精度有限。

- 全局多项式或低阶正交基难同时在陡峭与平缓区域都拟合好



符号回归与解析表达式发现

通过进化算法（如 GP）、稀疏回归（如 SINDy、PySR）自动寻找最优解析方程，兼顾精度与物理可解释性，已成为高精度拟合的热点。

- 缺少可解释性 对不同剖面不通用



从神经网络模型中抽象出方程

先用神经网络（如深度学习模型）在大数据集上学到复杂的非线性关系；再用符号回归、稀疏回归或可解释性分析方法，从训练好的网络里“提炼”出一个简洁的数学方程。

- 方程复杂性不确定 方程无法等同神经网络



数据驱动与混合建模方法

利用机器学习（神经网络、核回归等）建立高精度预测模型，并与物理约束或先验方程结合，形成“物理 + 数据”的混合校准模型，兼顾泛化与可靠性。

- 基于PINNs的融合架构主流 有先验的工作基础




方法论探索历程

几乎各类方法都可以达到一个很高的精度 但是无法达到**0.05K**




方法论实验记录 (2025.01-2025.11)



传统回归类方法

精度略低 但是参数过多, 在新的数据下缺少泛化性, 只在当时有限的数
据下表现效果良好。



符号回归与解析式发现


最终生成一个**显式的数学公式** 基于以后的基本公式形式, 缺少可解释性。

0	49.27	2.69392e+40	63	1.8643	2.10043	10.71m
1	32.44	2.12784e+23	61	1.81185	2.52654	8.99m
2	33.69	1.56892e+15	131	1.35531	1.18729	8.47m
3	34.93	2.00882e+17	127	1.29743	1.24624	8.41m
4	29.83	2.76237e+13	135	1.06086	1.08814	7.95m
5	54.10	2.56223e+17	133	0.882184	0.936999	10.71m
6	125.09	1.28427e+14	145	0.801332	0.812289	19.59m
7	128.29	2.48447e+14	147	0.646115	0.674082	20.82m
8	134.02	5.31382e+10	311	0.557151	0.610037	20.29m
9	133.90	5.57792e+10	149	0.520618	0.441435	20.40m
10	129.44	2.9846e+13	121	0.472972	0.503583	18.74m
11	136.48	5.81898e+11	125	0.461125	0.436862	18.76m
12	124.03	9.41901e+10	123	0.448119	0.555004	17.71m
13	120.42	1.56328e+11	129	0.426179	0.411445	17.51m
14	114.34	7.31876e+19	129	0.392121	0.387434	16.29m
15	113.59	6.02147e+10	125	0.358923	0.373526	15.57m
16	111.27	1.00044e+11	115	0.334177	0.321514	14.45m
17	114.64	4.89322e+12	109	0.328233	0.374961	14.19m
18	119.06	1.58924e+14	105	0.32496	0.392071	15.80m
19	108.55	8.43137e+10	113	0.323741	0.403024	13.95m


从神经网络模型中抽象出方程

符号回归作用于训练好的预测模型上的输入和输出, 缺少可解释性, **预测准确率不等于方程精度。**

但预测任务的效果要远远好于这个苛刻的回归任务



插曲：DeepOcean-PT 预测模型



1. **混合架构**：巧妙地集成了门控循环单元（GRU）和科尔莫戈罗夫-阿诺德网络（KAN）。GRU负责捕捉时间序列的依赖关系，而KAN则提供了强大的非线性表达能力。
2. **极致轻量**：整个模型仅包含约**4000个参数**，这在深度学习模型中是极为高效的设计。
3. 使用了跳跃连接来提高模型的稳定性和长期建模能力。
4. 注意只是初始架构后续还会继续优化（在更大的数据集上）

对比结果

Table 1. Comprehensive performance comparison of different models on the Cleaned WOD Dataset.

Model	$\text{MAE}_{\text{raw}} \downarrow$	$\text{RMSE}_{\text{raw}} \downarrow$	$R^2_{\text{raw}} \uparrow$	$\text{MSE}_{\text{raw}} \downarrow$	$\text{MAE}_{\text{std}} \downarrow$	$\text{RMSE}_{\text{std}} \downarrow$	$R^2_{\text{std}} \uparrow$	$\text{MSE}_{\text{std}} \downarrow$	#Params
TimesNet [10] (ICLR 2022)	0.219	0.387	0.904	0.202	0.128	0.234	0.904	0.111	4k
PatchTST [11] (ICLR 2023)	0.117	0.229	0.954	0.066	0.066	0.154	0.954	0.053	266k
TimeMixer [12] (ICLR 2024)	0.707	1.165	0.698	1.690	0.305	0.510	0.698	0.332	22k
DeepOcean-PT (Ours)	0.136	0.241	0.968	0.075	0.063	0.128	0.968	0.036	4k

1. MAE (Mean Absolute Error / 平均绝对误差) 模型预测值与真实观测值之间差值**平均绝对值**
2. RMSE (Root Mean Squared Error / 均方根误差)
3. **MSE** (Mean Squared Error / **均方误差**) 预测值与真实值之间差值的**平均平方值**
4. **R^2** (Coefficient of Determination / **决定系数**) 它衡量的是模型对数据变异性的解释程度 **拟合度**
5. #Params (Number of Parameters / 参数数量)
6. **raw (原始数据)**: 指标是在未经任何缩放处理的原始温度和压力数据上计算得出的。
7. **std (标准化数据)**: 指标是在数据经过标准化（减去均值并除以标准差）处理后计算得出的。

对比结果

Table 1. Comprehensive performance comparison of different models on the Cleaned WOD Dataset.

Model	$\text{MAE}_{\text{raw}} \downarrow$	$\text{RMSE}_{\text{raw}} \downarrow$	$R^2_{\text{raw}} \uparrow$	$\text{MSE}_{\text{raw}} \downarrow$	$\text{MAE}_{\text{std}} \downarrow$	$\text{RMSE}_{\text{std}} \downarrow$	$R^2_{\text{std}} \uparrow$	$\text{MSE}_{\text{std}} \downarrow$	#Params
TimesNet [10] (ICLR 2022)	0.219	0.387	0.904	0.202	0.128	0.234	0.904	0.111	4k
PatchTST [11] (ICLR 2023)	0.117	0.229	0.954	0.066	0.066	0.154	0.954	0.053	266k
TimeMixer [12] (ICLR 2024)	0.707	1.165	0.698	1.690	0.305	0.510	0.698	0.332	22k
DeepOcean-PT (Ours)	0.136	0.241	0.968	0.075	0.063	0.128	0.968	0.036	4k

综合性能: DeepOcean-PT 精度顶尖

最佳拟合度 (R^2 score): DeepOcean-PT 获得了全场最高的 R^2 分数 (**0.968**)。这通常是评估模型拟合优度的最关键指标,说明您的模型能最好地解释数据的变异性。

标准化数据性能: 在处理标准化 (std) 数据时, DeepOcean-PT 在所有误差指标上均取得了**最优成绩**,包括最低的 MAE (0.063)、RMSE (0.128) 和 MSE (0.036)。

原始数据性能: 在原始 (raw) 数据上, PatchTST 在几项误差指标 (MAE, RMSE, MSE) 上以微弱优势领先。然而, DeepOcean-PT 的表现紧随其后,差距非常小。

符号回归的作用 以及为什么最终没有选择的原因

... 海量的实测数据

$$(T_{raw}, P_{raw}) \xrightarrow{SR} f(T_{raw}, P_{raw}) \approx T_{true} \text{ 或 } P_{true}$$

优点:

1. 物理可解释性好
2. 不依赖复杂模型, 得到的表达式往往更简洁

缺点:

1. 如果数据噪声大、非线性强, 符号回归搜索不到稳定的解析方程
2. 对大规模数据, 符号回归计算压力大, 泛化受限

... 模型预测数据

$$(T_{raw}, P_{raw}) \xrightarrow{NN/ML} \hat{T}, \hat{P} \xrightarrow{SR} f(T_{raw}, P_{raw}) \approx \hat{T}, \hat{P}$$

优点:

1. 神经网络/机器学习模型先“学习”复杂非线性关系, 起到降噪和逼近作用
2. 符号回归再去“蒸馏”出一个方程, 相当于在平滑、抽象后的数据上搜索, 更容易得到稳定公式

缺点:

1. 得到的方程依赖于训练模型, 可能继承模型的偏差
2. 方程不是直接从真实数据里提炼, 而是从模型的“解释”里抽象, 物理可信度可能降低



数据爬取和数据精炼过程

提出了一个高标准高质量的数据精炼Workflow以供模型训练



数据源筛选

---I--	16	20661779	Wed, 19 Mar 2025 02:57:22 GMT	wod23_ctd_2023
---I--	16	137963589	Wed, 19 Mar 2025 02:57:22 GMT	wod23_ctd_2023 (2).nc
---I--	16	805790515	Wed, 19 Mar 2025 02:59:22 GMT	wod23_ctd_2023 (1).nc
---I--	16	185429580	Wed, 19 Mar 2025 03:02:46 GMT	wod23_ctd_2023.nc
---I--	16	66671503	Wed, 19 Mar 2025 02:58:02 GMT	CTDO1970.gz
---I--	16	63929	Wed, 19 Mar 2025 03:01:44 GMT	ocldb1757665187.1522306_OSD.nc.gz
---I--	16	4019303008	Wed, 19 Mar 2025 02:57:09 GMT	Don't show when downloads finish
---I--	16	44640332	Wed, 19 Mar 2025 02:59:44 GMT	wod23_mbt_1929.nc
---I--	16	360154930	Wed, 19 Mar 2025 03:02:22 GMT	wod23_ctd_1981.nc
---I--	16	87878896	Wed, 19 Mar 2025 02:57:52 GMT	wod23_osd_1918.nc
---I--	16	512342217	Wed, 19 Mar 2025 02:55:15 GMT	wod23_ctd_2023.nc
---I--	16	26777	Wed, 19 Mar 2025 02:57:25 GMT	wod23_pfl_2002.nc
---I--	16	193713089	Wed, 19 Mar 2025 02:54:35 GMT	wod23_gld_2010.nc
---I--	16	4234820	Wed, 19 Mar 2025 02:58:17 GMT	wod23_osd_1910.nc
---I--	16	69426865	Wed, 19 Mar 2025 02:55:26 GMT	wod23_mrb_2007.nc
---I--	16	83250234	Wed, 19 Mar 2025 02:59:46 GMT	wod23_uor_2003.nc
---I--	16	1195051427	Wed, 19 Mar 2025 02:55:45 GMT	wod23_osd_1984.nc
---I--	16	22715001	Wed, 19 Mar 2025 02:58:16 GMT	wod23_osd_1936.nc
---I--	16	148525467	Wed, 19 Mar 2025 02:58:07 GMT	wod23_mbt_1949.nc
---I--	16	34199672	Wed, 19 Mar 2025 03:01:42 GMT	wod23_drb_1985.nc
---I--	16	678102921	Wed, 19 Mar 2025 02:59:11 GMT	wod23_drb_2009.nc
---I--	16	71311814	Wed, 19 Mar 2025 02:58:20 GMT	wod23_mbt_1966.nc
---I--	16	123465359	Wed, 19 Mar 2025 02:57:28 GMT	wod23_osd_1925.nc
---I--	16	305436	Wed, 19 Mar 2025 02:55:26 GMT	wod23_ctd_2000.nc
---I--	16	104827298	Wed, 19 Mar 2025 02:55:29 GMT	wod23_gld_2015.nc
---I--	16	423704052	Wed, 19 Mar 2025 02:57:43 GMT	
---I--	16	20284523	Wed, 19 Mar 2025 02:58:18 GMT	
---I--	16	582765233	Wed, 19 Mar 2025 02:54:59 GMT	
---I--	16	3556590864	Wed, 19 Mar 2025 02:56:18 GMT	

精准筛选全球海洋数据库 寻找目标数据
1770-至今的所 ctd 数据 (近10年的最佳)

DESCRIPTION	DATA ACCESS	CITATION	DOCUMENTATION	SOFTWARE	METRICS								
ABSTRACT:	The World Ocean Database (WOD) has global ocean observed and standard depth data profiles. The World Ocean Atlas (WOA) has objectively analyzed climatological mean fields on both a quarter-degree and on a one-degree longitude by latitude grids. The gridded analyses are for annual, seasonal, and monthly means of six oceanographic variables: temperature, salinity, dissolved oxygen, nitrate, phosphate, and silicate on standard levels (typically at 102 depths, dependent on data availability). The products were derived at the Ocean Climate Laboratory (OCL) of the National Oceanographic Data Center (NODC). Development of the World Ocean products began in 1982 and they have been updated in 1994, 1998, 2001, 2005, 2009, 2013, 2018 and 2023. The featured products are now based on the 2023 versions. Some products from older version are still unique. The WOD is the world's largest profile collection covering the global ocean and contains measurements from 1800 through 2023. The WOA are climatological grids at fixed depths derived from quality checked WOD profiles. This is a recognized world-wide standard and is often referenced in oceanographic research.												
TEMPORAL RANGE:	1770-01-01 to 2024-10-22 (Entire dataset) PERIOD DETAILS BY DATASET PRODUCT 												
VARIABLES:	<table><tr><td>Chlorophyll</td><td>Dissolved Gases</td><td>Nitrate</td><td>Oxygen</td></tr><tr><td>Phosphate</td><td>Salinity</td><td>Silicate</td><td>Water Temperature</td></tr></table>					Chlorophyll	Dissolved Gases	Nitrate	Oxygen	Phosphate	Salinity	Silicate	Water Temperature
Chlorophyll	Dissolved Gases	Nitrate	Oxygen										
Phosphate	Salinity	Silicate	Water Temperature										
DATA TYPES:	Platform Observation												
DATA CONTRIBUTORS:	DOC/NOAA/NESDIS/NODC/OCL												
RELATED RESOURCES:	World Ocean Database												
TOTAL VOLUME:	1.27 TB (Entire dataset) VOLUME DETAILS BY DATASET PRODUCT 												
DATA FORMATS:	netCDF4												
MORE DETAILS:	View a more detailed summary of the data, including specific date ranges and locations by parameter												
METADATA RECORD:	Display in choose from the list format												
DATA LICENSE:	 This work is licensed under a Creative Commons Attribution 4.0 International License .												

全球海洋数据库
数据过于繁杂且单区域的数据量不足

...

数据结构 以 2023 为例

这是一个包含多次观测（casts）的集合文件。




casts: 9957: 数据集中总共包含了 **9957** 次独立的观测剖面。

Temperature obs: 1564166: 所有剖面加起来，总共有超过156万个温度观测点。

每个剖面都有对应的**经度**、**纬度**和**时间**信息。


z 记录了所有观测点的**深度**。

wod23_ctd_1990_deep_ocean_bottom2000 - 000000




...

数据结构 以 2023 为例



真是数据的显示数据点是一对多
一个深度应该是一个温度
且温度差距很大
有非常多的脏乱数据混在里面



初次尝试结果很差

太平洋数据集方程族测评分析报告

测评概述

在太平洋数据集 (woa23_t_B5C2_0.25_csv_pacific) 上对6个可解释方程族进行了全面测评, 涵盖四个季节 (春、夏、秋、冬), 每个季节约700万数据点。

测评方程族

```
1. **exp_fixed_c** (三参数): `T(D) = c + a * exp(-b * D)`
2. **rational_pade** (四参数): `T(D) = (a0 + a1*D)/(1 + b1*D + b2*D^2)`
3. **tanh** (四参数): `T(D) = m0 + m1*tanh((D - D0)/tau)`
4. **log_power_mix** (四参数): `T(D) = c0 + c1*log(1+D) + c2*D^alpha`
5. **double_tanh** (七参数): `T(D) = c0 + c1*tanh((D-D1)/tau1) + c2*tanh((D-D2)/tau2)`
6. **power_poly_mix** (四参数): `T(D) = c0 + c1*D + c2*D^alpha`
```

主要评估指标

- **MAE** (平均绝对误差): 衡量预测精度
- **RMSE** (均方根误差): 对较大误差更敏感
- **R²** (决定系数): 衡量模型解释方差的比例
- **MAPE** (平均绝对百分比误差): 相对误差度量

测评结果摘要

按MAE排序 (越小越好)

季节	最佳方程	MAE	次佳方程	MAE	最差方程	MAE
春季	rational_pade	4.4754	double_tanh	4.4800	log_power_mix	9.9350
夏季	rational_pade	4.4658	double_tanh	4.4725	log_power_mix	11.4242
秋季	rational_pade	4.4944	double_tanh	4.5018	log_power_mix	12.0606
冬季	rational_pade	4.3778	double_tanh	4.3876	log_power_mix	9.3735

按R²排序 (越大越好)

季节	最佳方程	R²	次佳方程	R²	最差方程	R²
春季	double_tanh	0.4488	rational_pade	0.4483	log_power_mix	-0.6914
夏季	rational_pade	0.4625	double_tanh	0.4624	log_power_mix	-1.1069
秋季	double_tanh	0.4631	rational_pade	0.4630	log_power_mix	-1.2703
冬季	double_tanh	0.4641	rational_pade	0.4635	log_power_mix	-0.5670

按R²排序 (越大越好)

季节	最佳方程	R²	次佳方程	R²	最差方程	R²
春季	double_tanh	0.4488	rational_pade	0.4483	log_power_mix	-0.6914
夏季	rational_pade	0.4625	double_tanh	0.4624	log_power_mix	-1.1069
秋季	double_tanh	0.4631	rational_pade	0.4630	log_power_mix	-1.2703
冬季	double_tanh	0.4641	rational_pade	0.4635	log_power_mix	-0.5670

详细分析

1. 性能最佳方程

****rational_pade**** 和 ****double_tanh**** 表现最为出色:
- ****rational_pade****: 在MAE指标上始终排名第一, 参数较少 (4个), 计算效率高
- ****double_tanh****: 在R²指标上表现最佳, 能更好捕捉温度剖面的双跃层结构

2. 性能中等方程

****tanh**** 和 ****power_poly_mix**** 表现中等:
- ****tanh****: 能较好模拟单一跃层, 但不如double_tanh精确
- ****power_poly_mix****: 性能接近rational_pade, 但略逊一筹

3. 性能较差方程

****exp_fixed_c**** 和 ****log_power_mix**** 表现较差:
- ****exp_fixed_c****: 过于简化, 无法捕捉温度剖面的复杂结构
- ****log_power_mix****: 在所有季节都表现最差, R²甚至为负值

4. 季节性差异分析

- ****冬季****: 整体性能最佳, MAE和R²指标最好
- ****夏季和秋季****: 性能相近, 略差于冬季
- ****春季****: 性能相对最差, 可能与季节性过渡期有关

参数敏感性分析

参数数量影响

- ****3参数****: exp_fixed_c - 过于简单, 拟合能力不足
- ****4参数****: rational_pade, tanh, log_power_mix, power_poly_mix - 适中的复杂度
- ****7参数****: double_tanh - 最高复杂度, 拟合能力最强

参数敏感性分析

参数数量影响

- ****3参数****: exp_fixed_c - 过于简单, 拟合能力不足
- ****4参数****: rational_pade, tanh, log_power_mix, power_poly_mix - 适中的复杂度
- ****7参数****: double_tanh - 最高复杂度, 拟合能力最强

物理可解释性

- ****tanh系列****: 具有明确的物理意义 (跃层中心、厚度)
- ****rational_pade****: 数学形式优雅, 但物理意义相对抽象
- ****混合模型****: 结合不同函数特性, 但可解释性降低

推荐使用建议

首选方程

1. ****rational_pade****: 平衡性能与复杂度, 计算效率高
2. ****double_tanh****: 最高精度, 适合需要精确建模的应用

适用场景

- ****实时应用****: 推荐rational_pade (计算效率高)
- ****科研分析****: 推荐double_tanh (精度最高)
- ****教学演示****: 推荐tanh (物理意义明确)

参数调优建议

- 对于不同海区 and 季节, 建议重新拟合参数
- double_tanh的参数网格搜索范围可进一步优化

技术说明

数据规模

- 每个季节约700-730万数据点
- 102个标准深度层 (0-700米)
- 覆盖太平洋区域完整格点

评估方法


- 逐点评估, 避免空间平均带来的信息损失
- 使用标准统计指标进行综合评估
- 考虑不同优化目标 (MAE最小化 vs R²最大化)

结论


在太平洋温度-深度剖面建模中, ****rational_pade****和****double_tanh****方程族表现最佳。rational_pade在计算效率和性能之间达到最佳平衡, 而double_tanh提供了最高的建模精度。log_power_mix和exp_fixed_c方程族在此数据集上表现不佳, 不建议使用。

数据源筛选 聚焦一个相对稳定的数据区域


基于温度可视化的区域筛选(通过温度差异)



没有选两极的原因 不满足大部分花
海洋场景的规律 太冷了 温度很低规
律和基本海域的规律相违背



随着深度降低深度分布相对集中的
区域即是我们要寻找的普遍规律的
区域



基于数据源的考察和区域筛选得出
合适的实验数据区域

数据精炼到高质量的深海温度传感数据集

三级数据精炼与物理一致性


1. 清除所有违反物理定律的剖面，使数据满足基础海洋热力学结构。**(静力稳定检查)** $\frac{d\rho}{dz} \geq 0$

2. 多尺度噪声剥离
海洋剖面中的噪声包括：传感器局地尖峰，数据插值伪像，近混合层高频震荡，温跃层突变中的非物理锯齿。

局部多尺度滤波保证平滑
平滑但保留物理梯度

$$\text{minimize} \int \left(\frac{d^2 T}{dz^2} \right)^2 dz$$

3. 分段结构化解析拟合准备
利用温度极大梯度点位置（温跃层中心）深海温度梯度等关键信息找到深度分层的具体位置



数据精炼到高质量的深海温度传感数据集

2700万的高质量温压传感数据



处理的温度和压力观测记录，其量级在**100亿到200亿**之间。

多个数据源筛选

局部海域阿拉斯加湾数据补充

最全的阿拉斯加湾的高质量温度压力数据

为PINNs模型训练提供充足的高质量数据





方法论：混合基函数 + PINN 残差

在300多个模型及回归方法中达到最高的0.05K精度



核心思路



混合基函数 物理启发的可解释主趋势

1. 结构固定、物理启发式设计的函数库 **既保留非线性，又具备连续、可控、可约束的结构**，因此在海洋剖面这种强物理结构的任务中更稳定、更可信。



“结构化主-残分解”的温度剖面建模范式

把 **宏观的物理趋势** 与 **微尺度的非线性扰动** 解耦，使模型既具备物理可解释性，又保留通用逼近能力。



遵守深海规律的梯度物理残差PINN

海洋中温度随深度的变化遵循稳定的物理规律，例如缓慢减温、深层弱梯度等，**不依赖 PDE，而依赖“物理期望梯度”来稳定训练。**


混合基函数 VS 符号回归

混合基函数


根据数据拟合情况给出适合的物理先验，结构固定、物理启发式设计的函数库

通过解析线性回归或轻量 grid-search 优化系数
更快收敛、更稳定、更容易复现。

可解释性更高、物理意义更明确



VS



符号回归

符号回归通过自由组合算子 (+、-、×、÷、exp、log、sin...) 自动生成表达式，使其
搜索空间极其巨大且结构不稳定。

随机生成的表达式层级深、分叉多，极易出现病态形式。


符号回归优化的是 **离散结构 + 连续参数** 的双层搜索且高度依赖进化策略或随机搜索，
局部最优泛滥、搜索震荡极大。

选择梯度约束的原因

深海海洋学中，温度分布满足复杂的 PDE，这些 PDE 需要流速、盐度、经纬度输送项，难以在一维剖面上闭合。

PDE 是 **硬约束(hard constraint)**：模型必须精确满足 PDE，每个项都需被建模。

不解 PDE 但保证解具有与 PDE 解同样的“光滑性”和“能量结构”
使用梯度



解析解的形式

A.1 ITS-90 temperature
A.2 Sea pressure, gauge pressure and absolute pressure
A.3 Reference Composition and the Reference-Composition Salinity Scale ...
A.4 Absolute Salinity
A.5 Spatial variations in seawater composition
A.6 Gibbs function of seawater
A.7 The fundamental thermodynamic relation
A.8 The “conservative” and “isobaric conservative” properties
A.9 The “potential” property
A.10 Proof that $\theta = \theta(S_A, \eta)$ and $\Theta = \Theta(S_A, \theta)$
A.11 Various isobaric derivatives of specific enthalpy
A.12 Differential relationships between η , θ , Θ and S_A
A.13 The First Law of Thermodynamics
A.14 Advective and diffusive “heat” fluxes
A.15 Derivation of the expressions for α^θ , β^θ , α^Θ and β^Θ
A.16 Non-conservative production of entropy
A.17 Non-conservative production of potential temperature
A.18 Non-conservative production of Conservative Temperature
A.19 Non-conservative production of density and of potential density
A.20 The representation of salinity in numerical ocean models
A.21 The material derivatives of S , S_A , S_R and Θ in a turbulent ocean
A.22 The material derivatives of density and of locally-referenced potential density; the diapycnal velocity $\tilde{v}$
A.23 The water-mass transformation equation
A.24 Conservation equations written in potential density coordinates
A.25 The vertical velocity through a general surface
A.26 The material derivative of potential density
A.27 The diapycnal velocity of layered ocean models (without rotation of the mixing tensor)
A.28 The material derivative of orthobaric density
A.29 The material derivative of Neutral Density
A.30 Computationally efficient 25-term expressions for the density of seawater in terms of Θ and θ



实验结果和讨论

行业内首个温度压力剖面拟合的可解释性技术框架



实验一 基于物理信息神经网络的海洋温压关系方程结构对比实验

项数增加 找到最终的形式 附带精度变化

$$\hat{T}_2(P) = 5.12742481 - 2.64606596 \times 10^{-3} P + 5.35595691 \times 10^{-7} P^2.$$

MAE 0.2118 °C

$$\hat{T}_4(P) = 5.05404204 - 2.26920822 \times 10^{-3} P - 3.96617497 \times 10^{-8} P^2 + 3.37214976 \times 10^{-10} P^3 - 6.71345918 \times 10^{-14} P^4.$$

MAE 0.1481 °C

令 $x = (P - 1641.2335)/990.7445$, 则

$$\hat{T}_5(P) = 2.20411614 - 0.86369338 x + 0.41811779 x^2 - 0.08912643 x^3 - 0.00667122 x^4 + 0.00535626 x^5.$$

MAE 0.05328 °C

同样以 $x = (P - 1641.2335)/990.7445$,

$$\hat{T}_6(P) = 2.20278856 - 0.87714145 x + 0.42640403 x^2 - 0.06258684 x^3 - 0.01749463 x^4 - 0.00448305 x^5 + 0.00410846 x^6.$$

MAE 0.05400 °C

以 $z = (P - 1641.2335)/990.7445$:

$$\begin{aligned} \hat{T}_8^A(P) = & 72.5243001 + 130.024309 z - 1.45894798 z^2 + 0.148251154 z^3 \\ & + 23.8341486 \ln(P) - 6.13065083 \sqrt{P} + 2610.76502 \frac{1}{P} - 9.36352770 (\ln(P) \cdot z). \end{aligned}$$

MAE 0.05107 °C

实验一 基于物理信息神经网络的海洋温压关系方程结构对比实验

通用方程形式

标准函数形式（线性组合模型）：


$$f(P) = \text{coef}_1 \cdot 1 + \text{coef}_P \cdot P + \text{coef}_{\ln(P)} \cdot \ln(P) + \text{coef}_{\sqrt{P}} \cdot \sqrt{P} + \text{coef}_{\exp(-P/500)} \cdot \exp\left(-\frac{P}{500}\right) + \text{coef}_{\exp(-P/1200)} \cdot \exp\left(-\frac{P}{1200}\right) + \text{coef}_{\frac{1}{P+50}} \cdot \frac{1}{P+50} + \text{coef}_{\frac{1}{P+500}} \cdot \frac{1}{P+500}$$

具体系数赋值：

$$\begin{aligned}\text{coef}_1 &= 0.575963 \\ \text{coef}_P &= -0.000714 \\ \text{coef}_{\ln(P)} &= 0.310251 \\ \text{coef}_{\sqrt{P}} &= 0.002999 \\ \text{coef}_{\exp(-P/500)} &= 2.356074 \\ \text{coef}_{\exp(-P/1200)} &= 1.290324 \\ \text{coef}_{\frac{1}{P+50}} &= 0.041274 \\ \text{coef}_{\frac{1}{P+500}} &= 0.005494\end{aligned}$$

完整展开形式：

$$f(P) = 0.575963 - 0.000714 \cdot P + 0.310251 \cdot \ln(P) + 0.002999 \cdot \sqrt{P} + 2.356074 \cdot \exp\left(-\frac{P}{500}\right) + 1.290324 \cdot \exp\left(-\frac{P}{1200}\right) + 0.041274 \cdot \frac{1}{P+50} + 0.005494 \cdot \frac{1}{P+500}$$



实验二 基线模型性能对比实验

模型

模型种类
34种

经典统计回归
11种

核方法 / 浅层非线性 ML
12种

树模型 + 集成学习
7种

混合学习
4种

结果

共测试了300多种不同参数的模型

其中最好的结果为0.054366仍低于本方法
侧面表示已有的所有方法的上限就是0.05左右了
我们接近最终的最好的结果

排名	模型系列 (Series)	最佳模型 (Best Model Configuration)	mae (越低越好)
1	$\hat{T}_{12}$ (固定方程)	$\hat{T}_{12}$ (固定方程)	0.054366
2	$\hat{T}_{11}$ (固定方程)	$\hat{T}_{11}$ (固定方程)	0.054613
3	$\hat{T}_{1^2}$ (固定方程)	$\hat{T}_{1^2}$ (固定方程)	0.055348
4	$\hat{T}_s$ (固定方程)	$\hat{T}_s$ (固定方程)	0.055462
5	CatBoost	CatBoost (iter=2000,depth=10,lr=0.1)	0.056083
6	$\hat{T}_{10}$ (固定方程)	$\hat{T}_{10}$ (固定方程)	0.056093
7	$\hat{T}_s$ (固定方程)	$\hat{T}_s$ (固定方程)	0.056158
8	ExtraTrees	ExtraTrees (n=400,depth=8,leaf=1)	0.056226
9	LightGBM	LightGBM (n=400,depth=16,leaf=62)	0.056342
10	XGBoost	XGBoost (n=200,depth=10,lr=0.1)	0.056763

train_count	test_count	category	model	mae
8000	2000	方程基线	$\hat{T}_s$ (固定方程)	0.055348070744284515
8000	2000	经典回归	Linear Regression	0.29625297557491637
8000	2000	经典回归	Polynomial Regression (deg=5)	0.0709656645059306
8000	2000	经典回归	SVR (RBF)	0.05869561624455508
8000	2000	经典回归	Random Forest	0.06250137998536764
8000	2000	经典回归	Spline Regression (B-spline, 10 knots)	0.05726990049851588
8000	2000	经典回归	Nystroem RBF + Ridge (Kriging approx)	0.05683529459589175
8000	2000	经典回归	Nystroem RBF(1024) + Ridge	0.05683529451168708
8000	2000	经典回归	KNN (k=25, distance)	0.06506907183384626
8000	2000	经典回归	Decision Tree (max_depth=18)	0.06405904970280889
8000	2000	经典回归	ExtraTrees	0.065122429424489
8000	2000	经典回归	ElasticNet	0.2963393118197812
8000	2000	经典回归	KernelRidge (RBF)	0.05687763687685035
8000	2000	经典回归	HistGradientBoosting	0.056612553975845394
8000	2000	经典回归	GradientBoosting	0.05687744167331711
8000	2000	经典回归	AdaBoost (Tree base)	0.0584324835076929
8000	2000	经典回归	Bagging (Tree base)	0.06007547725033119
8000	2000	经典回归	BayesianRidge	0.29625521538157457
8000	2000	经典回归	HuberRegressor	0.27281943346636245
8000	2000	经典回归	Lasso	0.29635769480301066
8000	2000	经典回归	LinearSVR	0.26772264943021745
8000	2000	经典回归	NuSVR (RBF)	0.05716882364326327
8000	2000	经典回归	SVR (poly, deg=3)	0.6108432438785689
8000	2000	经典回归	SGDRegressor	0.29823451379546456
8000	2000	经典回归	PassiveAggressiveRegressor	1.0688384892653453
8000	2000	经典回归	RANSACRegressor	0.29133530285003617
8000	2000	经典回归	TheilSenRegressor	0.28329534672069456
8000	2000	经典回归	RadiusNeighbors (radius=1.0)	0.25219264916478973
8000	2000	经典回归	KernelRidge (poly, deg=3)	0.05978189128562318


实验三 按照四季划分的方程

```
- **Season1 (01-22 → 05-27)**: coef_1=0.575963, coef_P=-0.000714, coef_ln(P)=0.310251, coef_sqrt(P)=0.002999,
coef_exp(-P/500)=2.356074, coef_exp(-P/1200)=1.290324, coef_1/(P+50)=0.041274, coef_1/(P+500)=0.005494
- **Season2 (05-27 → 07-21)**: coef_1=0.594587, coef_P=-0.000761, coef_ln(P)=0.320774, coef_sqrt(P)=0.002806,
coef_exp(-P/500)=2.325574, coef_exp(-P/1200)=1.302425, coef_1/(P+50)=0.043476, coef_1/(P+500)=0.005258
- **Season3 (07-21 → 10-20)**: coef_1=0.543880, coef_P=-0.000983, coef_ln(P)=0.307154, coef_sqrt(P)=0.016287,
coef_exp(-P/500)=2.113262, coef_exp(-P/1200)=1.212209, coef_1/(P+50)=0.012660, coef_1/(P+500)=0.003176
- **Season4 (10-20 → 01-22)**: coef_1=0.518960, coef_P=-0.001025, coef_ln(P)=0.298059, coef_sqrt(P)=0.020408,
coef_exp(-P/500)=2.111670, coef_exp(-P/1200)=1.193199, coef_1/(P+50)=0.002496, coef_1/(P+500)=0.002885
```


季节指标

季节	日期范围	原始样本量	train MAE	val MAE	val RMSE	val R ²	PDE 均值	PDE 95%	样本(train/val)
Season1	01-22 → 05-27	9518725	0.0388	0.0385	0.0672	0.9934	2.08e-06	6.78e-06	160000/40000
Season2	05-27 → 07-21	3582919	0.0683	0.0681	0.1410	0.9733	2.17e-06	6.69e-06	160000/40000
Season3	07-21 → 10-20	6482500	0.0539	0.0536	0.0775	0.9908	1.73e-06	4.60e-06	160000/40000
Season4	10-20 → 01-22	7523621	0.0484	0.0482	0.0644	0.9932	1.64e-06	4.32e-06	160000/40000

实验三 按照四季划分的方程 (误差可视化)



实验四 按照年份划分的方程（误差可视化）




实验五 深度分层拟合实验

评估基准： 将分层方案（如3层、4层、6层模型）的性能，与实验一得到的“通用方程”（全局模型）的逐米高分辨率精度（MAE、RMSE、 R^2 ）进行详细对比。

探索用多个“局部”最优模型组合，是否能比一个“全局”最优模型（实验一的结果）更准确地解析完整的海洋温压剖面，特别是在提升局部精度和整体稳定性方面。

下图展示了四季方程的温度误差随着深度变化的对比，**可以看出深海温度随压力的变化趋势误差在逐渐稳定趋近于0**
也可以得出表层海洋温度的不稳定是一直存在的遵循海洋 物理客观规律




实验六 基于最优设计点的方程系数快速推理实验

目的：在**极大压缩观测数据量**的前提下，能否快速、稳健地反演出方程的全局系数。用最少的点拟合海洋剖面。

实验中找寻了三种比较好的选点方式

1. **Global (全局系数)**: 使用所有 2710 万条数据拟合的基准方程。
2. **D-opt-8 (D-optimal 8点)**: 使用 D-optimal 设计（一种统计实验设计方法）选出 8 个目标点。
3. **Uniform-8 (均匀 8点)**: 按压力分位数均匀选取 8 个目标点。 **(效果最差)**



最少点确定最优海洋剖面曲线

选点方式：

Uniform-8 目标点 `uniform\_P`：`[349, 838, 1326, 1816, 2344, 2832, 3321, 3809]` (dbar)

D-opt-8 目标点 `targets\_P`：`[244, 160, 493, 4025, 1025, 241, 1909, 3323]` (dbar)

误差对比：

100–500 dbar: Global 0.0122; Uniform-8 0.1134; **D-opt-8 0.0322** (浅层 Uniform-8 误差偏大)

- 500–1500 dbar: Global 0.0066; **Uniform-8 0.0242**; D-opt-8 0.0313

- 1500–2500 dbar: Global 0.0041; **Uniform-8 0.0059**; D-opt-8 0.0234 (Uniform-8 在中层更优)

- 2500–3500 dbar: Global 0.0009; **Uniform-8 0.0046**; D-opt-8 0.0117

- 3500–4500 dbar: Global 0.0045; **Uniform-8 0.0032**; D-opt-8 0.0171 (Uniform-8 在深层更优)

Uniform-8 D-opt-8 混合选点：

目标点 `P`：`[244, 160, 493, 241, 349, 838, 4025, 1025, 1909, 3323]` **10点确定最佳海洋温压剖面**

结论 研究总结

Salary |



标准数据集

- 通过数据源精准筛选以及数据清洗补足构建了适合温度压力剖面拟合的阿拉斯加湾海域的数据，能反应深海剖面规律的实验样本。



Ocean PINN

- 提出了一种以“物理梯度约束 + 混合基函数解析模型”为核心的新型深海温度剖面拟合框架，通过显式解析基与隐式物理梯度惩罚联合优化，在无需求解完整 PDE 的条件下获得高精度、可解释、可泛化的温度-压力解析表达式。



表现效果

- 拟合全局方程准确性最高，达到0.05K精度。
- 同步解析出四季方程，分年份方程，按深度分层方程以及精度误差关系。
- 确定最佳的选点只需要10点配合全局方程达成高精度温压剖面拟合。

基于数据驱动与深度学习

在原位自校准温度压力传感器中对
温度压力方程超高精度拟合的研究

汇报人：韩普宇

单位：南方科技大学 \ 南方海洋实验室

邮箱：12432627@mail.sustech.edu.cn